

TP1 - Processamento Distribuído de Dados

Raphaela Maria Costa e Silva - 2020006973

1 - Primeiro, as duplicatas foram removidas para evitar repetições. Em seguida, calculei o valor mínimo, a média e o máximo das durações.

Para eliminar valores extremos, apliquei o método do intervalo interquartil (IQR), filtrando faixas fora do intervalo $Q1 - 1.5 \times IQR$ a $Q1 + 1.5 \times IQR$ e $Q3 - 1.5 \times IQR$ a $Q3 + 1.5 \times IQR$. Após essa filtragem, os novos valores mínimo, médio e máximo mostraram uma distribuição mais equilibrada e representativa das músicas típicas.

A comparação final indicou que a remoção de outliers reduziu distorções e aproximou as estatísticas da realidade do conjunto de dados, confirmando a eficácia do uso do IQR nesse tipo de análise.

É possível ver abaixo os resultados, a esquerda o antes do processamento e à direita o depois do processamento.

min_valor	media_valor	max_valor
0	243482.209659	10435467


min_valor	media_valor	max_valor
58775	226448.903941	402066

2 - Primeiro, foram selecionados os cinco artistas mais frequentes considerando apenas pares únicos de artista e playlist, garantindo que cada artista fosse contado uma vez por playlist.

Em seguida, foi adicionado a coluna "ano" do dataset, extraída da data de modificação, e combinados com as informações das faixas para permitir a análise temporal. Filtrou-se apenas os registros dos cinco artistas mais populares para focar na evolução de sua presença.

Após isso, os dados foram agregados por ano e artista, transformando-se em uma tabela no formato pivot para facilitar a visualização. Por fim, um gráfico de linhas mostrou como cada artista apareceu nas playlists ao longo dos anos, permitindo

identificar tendências, picos de popularidade e mudanças no interesse dos usuários.




Em 2017, a análise das cinco artistas mais populares nas playlists revelou que Drake liderava com presença em cerca de 80.000 playlists, enquanto The Weeknd, Rihanna, Kendrick Lamar e Kanye West apareciam em aproximadamente 40.000 playlists cada, ou seja, metade da quantidade de Drake. Observa-se também que, nos anos anteriores, a presença desses artistas nas playlists só aumenta a cada ano, indicando crescimento contínuo de popularidade e maior incorporação de suas músicas nas playlists ao longo do tempo.

3 - Primeiro, foi feita a junção das playlists com as faixas para obter todas as músicas associadas a cada playlist. Para cada playlist, calculou-se o número de faixas de cada artista (`artist_song_count`) e o total de faixas na playlist (`num_songs_playlist`), permitindo calcular a fração de cada artista na playlist.

Em seguida, identificou-se, para cada playlist, o artista mais presente, ou seja, aquele com a maior fração de faixas. Essa informação foi organizada em uma tabela que indicava, para cada playlist, o artista predominante e sua prevalência.

Por fim, os dados foram convertidos para pandas para gerar uma CDF, que mostra a distribuição acumulada da prevalência dos artistas mais frequentes nas playlists. O gráfico resultante permite visualizar quantas playlists têm artistas altamente predominantes versus playlists com maior diversidade, oferecendo insights sobre padrões de concentração de artistas nas playlists analisadas.



A análise da CDF da prevalência de artistas nas playlists mostrou que aproximadamente 90% das playlists têm um artista predominante com cerca de 20% das faixas da playlist, ou seja, a fração acumulada de 0,9 é atingida quando um único artista representa aproximadamente 0,2 da playlist. Isso indica que, na grande maioria das playlists, mesmo o artista mais frequente raramente domina completamente a lista, evidenciando uma distribuição relativamente equilibrada de artistas dentro das playlists.